HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG

KHOA SAU ĐẠI HỌC

BÁO CÁO BÀI TẬP LỚN
CÁC DỮ LIỆU LỚN

ĐỀ TÀI:

Giảng viên hướng dẫn	**: TS. Nguyễn Kiều Linh**
Lớp	**: M25CQHT02-B**
Nhóm	**: Nhóm 01**

01. Trần Hồng Ánh	**MHV:** B25CHKH078
02. Đỗ Đức Long	**MHV:** B25CHKH105
03. Đặng Anh Quân	**MHV:** B25CHKH110
04. Nguyễn Thuỳ Linh	**MHV:** B25CHKH102
05. Nguyễn Ngọc Anh	**MHV:** B25CHKH077

Hà Nội – 2026

Đề tài: Math Data Lake: Ingestion

Báo cáo tuần 2

1. Data unit + partition key

Dữ liệu dự kiến thu thập

Nguồn	Mô tả	Một số trường quan trọng	Số lượng bản ghi dự kiến
NuminaMath	Dữ liệu bài toán và lời giải từng bước bằng ngôn ngữ tự nhiên, có biểu thức LaTeX.	problem, solution, messages, source	859.594
ProofNet	Dữ liệu phát biểu và chứng minh bằng ngôn ngữ tự nhiên, kèm phát biểu hình thức bằng Lean 3.	id, nl_statement, nl_proof, formal_statement, src_header	371
LeanDojo	Dữ liệu định lý Lean 4 cùng chuỗi tactic, trạng thái chứng minh và tham chiếu đến các khai báo liên quan.	file_path, full_name, commit, traced_tactics	122.517
Tổng			**982.482**

Dữ liệu đầu ra dự kiến được tổ chức theo dataset và split. Để xử lý song song, mỗi nhóm lớn được chia tiếp thành các bucket bằng hash ổn định của record_id. Số bucket được cấu hình theo quy mô dữ liệu và tài nguyên. Nhóm sẽ kiểm tra số bản ghi, dung lượng và thời gian xử lý từng partition để đánh giá lệch tải.

2. Map/worker contract

- Input**:** Một batch bản ghi từ một trong ba nguồn, kèm thông tin nguồn và phiên bản.

- Xử lý và output: Kiểm tra trường bắt buộc, chuẩn hóa tên trường và kiểu dữ liệu; xuất bản ghi theo lược đồ chung, giữ thông tin nguồn gốc.

- Lỗi: Tách bản ghi không hợp lệ vào tập lỗi, ghi nguyên nhân để kiểm tra lại.

- Idempotent: Dự kiến bảo đảm khi xử lý lại cùng batch, kết quả trong kho không bị nhân đôi.

3. Aggregation/merge

Gom các bản ghi hợp lệ từ các worker vào kho dữ liệu chung, tổ chức theo nguồn và split. Dự kiến xử lý bản ghi trùng theo record_id, ghi nhận trường hợp cùng ID nhưng khác nội dung. Đồng thời tổng hợp số lượng bản ghi đầu vào, hợp lệ, lỗi và trùng theo từng nguồn để đánh giá chất lượng dữ liệu.

4. Bottleneck hypothesis

Dự kiến điểm nghẽn chủ yếu nằm ở RAM khi đọc và phân tích các tệp JSON lớn của LeanDojo, cùng tốc độ đọc/ghi khi chuyển dữ liệu sang kho chung. Ngoài ra, độ dài lời giải và số lượng tactic khác nhau có thể gây lệch tải giữa các worker. Nhóm sẽ đo mức sử dụng RAM, thời gian đọc/ghi và thời gian xử lý từng partition để kiểm chứng.

5. Scalability experiment

Dự kiến đánh giá khả năng mở rộng với ba mức dữ liệu: 100.000, 500.000 và toàn bộ dữ liệu (khoảng 982.000 bản ghi theo thống kê hiện có), trên ít nhất hai cấu hình tài nguyên. Mỗi trường hợp được chạy lặp ít nhất ba lần, đo thời gian thực thi (runtime), thông lượng (throughput), mức sử dụng RAM và số byte đọc/ghi (bytes I/O). Đồng thời, nhóm sẽ so sánh ảnh hưởng của định dạng lưu trữ, cách chia partition và kích thước file đến hiệu năng xử lý.

6. Evidence

Dự kiến kiểm tra nguồn, phiên bản, số bản ghi và dung lượng đầu vào; lưu cấu hình tài nguyên, số partition, định dạng và kích thước file của từng thí nghiệm. Mỗi lần chạy sẽ ghi nhận runtime, throughput, RAM cao nhất và tổng số byte đọc/ghi, đồng thời thống kê số bản ghi hợp lệ, lỗi, trùng, thiếu trường bắt buộc và tham chiếu LeanDojo không nối được với corpus.

Nhóm sẽ đối chiếu đầu ra giữa các cấu hình, kiểm tra chạy lại không tạo dữ liệu trùng và theo dõi thời gian xử lý từng partition để phát hiện lệch tải. Log, cấu hình và bảng kết quả CSV được lưu làm bằng chứng để xây dựng biểu đồ so sánh và phân tích lỗi.